Metodología de la Investigación

CRISP-DM

Predicción de diabetes

Fabiola López Velázquez, Jorge Luis Ortiz Libreros, Joshua Iván Olivares Blanco

Proyecto CRISP-DM

Aplicado a la predicción del riesgo de diabetes

El proyecto CRISP-DM es la forma de estructurar proyectos de análisis y minería de datos, y dentro de la materia aborda gran parte del trabajo para resolver problemas complejos con datos.

1. Comprensión del Negocio (Business Understanding)

Nuestro objetivo del tema es analizar un conjunto de datos de pacientes para así descubrir las variables asociadas al riesgo de diabetes y construir un modelo que clasifique a nuevos pacientes, ya que el nivel de riesgo se clasifica en las categorías **Low**, **Moderate** y **High**. Este modelo busca ser una herramienta de apoyo para que el personal de salud priorice el seguimiento de los pacientes que lo requieran, dejando muy en claro que esto no sustituye un diagnóstico médico formal.

2. Comprensión de los Datos (Data Understanding)

Utilizamos la base de datos diabetes sacada de la página de Kaggle, la cual tiene 15,000 registros y 19 variables por paciente. Estas variables abarcan datos demográficos, clínicos/biométricos, hábitos de estilo de vida y antecedentes familiares. Se verificó que no existen registros duplicados, pero si se identificaron valores faltantes en tres variables categóricas: smoking_status (472 casos), income_bracket (463 casos) y alcohol_consumption (3,788 casos)

3. Preparación de los Datos (Data Preparation)

Dentro de esta fase, la variable patient_id fue descartada por ser un identificador único sin capacidad predictiva. Los valores faltantes se reemplazaron por la categoría "Unknown". También, las variables categóricas y la variable objetivo se transformaron a tipo factor, ya que el algoritmo de árbol de decisión lo requiere.

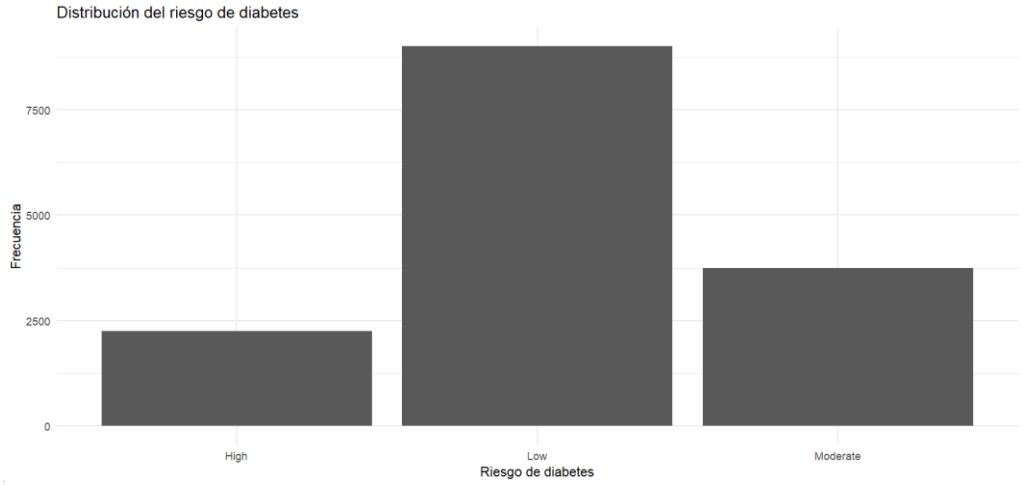
Por eso la base se dividió mediante muestreo estratificado en 70% para entrenamiento y 30% para datos de prueba

4. Modelado (Modeling)

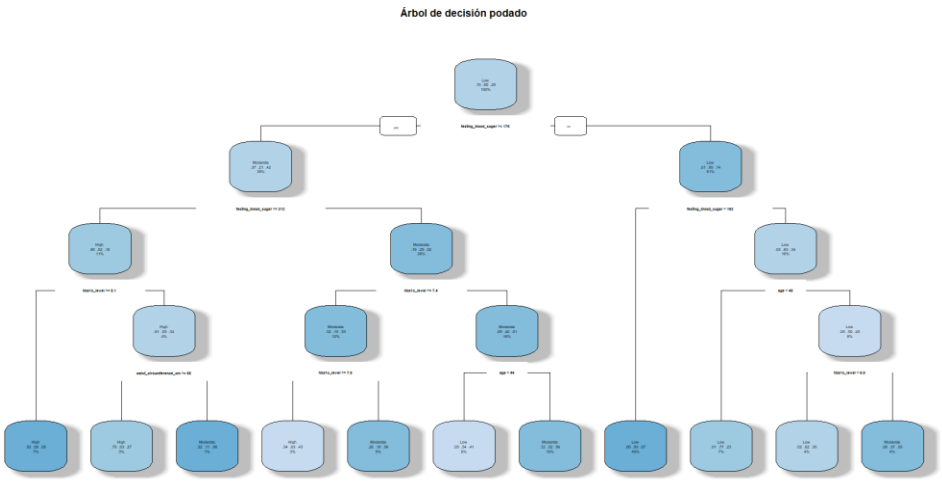
Implementamos un árbol de decisión empleando el algoritmo CART a través de la función rpart. Con parámetros de control: cp = 0.001, minsplit = 20 y maxdepth = 4.

Para optimizar el rendimiento y evitar el sobreajuste, el árbol inicial fue podado, eligiendo el valor de complejidad (cp) que presentó el menor error de validación cruzada.

Interpretación: Observamos que la clase 'Low' es la predominante (60%), seguida de 'Moderate' (25%) y 'High' (15%). Esta distribución refleja un desbalance de clases natural en la población



*Interpretación: El nodo raíz confirma que la glucosa en ayunas (**fasting_blood_sugar >= 175**) es el primer punto de corte crítico. Las ramificaciones secundarias evalúan la hemoglobina glucosilada (**hba1c_level**) y la edad para clasificar el nivel de riesgo final.*

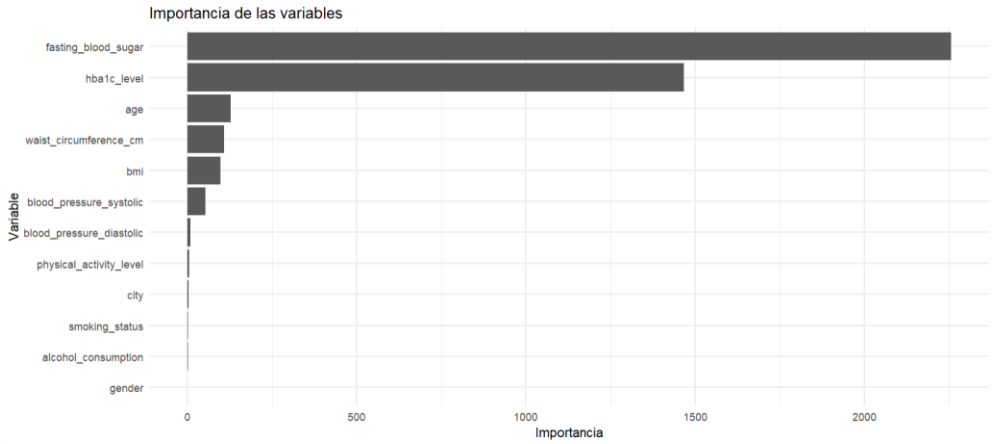


5. Evaluación (Evaluation)

Analizamos el modelo mediante una matriz de confusión sobre los datos de prueba, obteniendo métricas de exactitud global y métricas por categoría como sensibilidad y especificidad.

La glucosa en ayunas (fasting_blood_sugar) es el factor más determinante, especialmente con valores altos que sean >=175, que concentran la mayoría de los casos de riesgo Alto. Para distinguir entre riesgo Moderado y Bajo, el nivel de hemoglobina glucosilada (hba1c_level) salió como el segundo criterio más relevante. También la edad y la circunferencia de cintura ayudaron a afinar la clasificación dentro de los grupos de riesgo Bajo y Moderado.

Interpretación: Podemos confirmar que los parámetros biométricos de glucosa en ayunas y hemoglobina glucosilada concentran más del 80% de la capacidad predictiva del modelo, desplazando a variables demográficas o de hábitos.



6. Despliegue (Deployment)

Nuestro despliegue se materializa en la generación del informe final y la visualización de los resultados mediante gráficas del árbol podado (rpart.plot). Los resultados pueden implementarse en el futuro para orientar decisiones clínicas tempranas de manera accesible. Y como plan a futuro, se propone comparar este modelo con otros algoritmos para intentar mejorar la exactitud, pero manteniendo la interpretabilidad del modelo.

Conclusión:

Durante el desarrollo de este trabajo demostramos cómo la metodología CRISP-DM permite estructurar un proyecto desde la comprensión del problema clínico hasta la evaluación e interpretación del modelo.

También, a través del árbol de decisión, fue posible construir un modelo preciso, y altamente interpretable, confirmando que la glucosa en ayunas (fasting_blood_sugar) y la hemoglobina glucosilada (hba1c_level) son los factores metabólicos con mayor peso predictivo para determinar el riesgo de diabetes.

Haciendo uso de la metodología CRISP-DM se asegura que los resultados no se queden en un análisis aislado, sino que sirvan como una herramienta real de apoyo en el triaje de pacientes para el personal de salud.

Referencias:

Fayyad, U. M., Piatetsky-Shapiro, G., & Smyth, P. (1996). *From data mining to knowledge discovery in databases*. AI Magazine, 17(3), 37–54. https://doi.org/10.1609/aimag.v17i3.1230

Fayyad, U. M., Piatetsky-Shapiro, G., & Smyth, P. (1996). *The KDD process for extracting useful knowledge from volumes of data*. Communications of the ACM, 39(11), 27–34. https://doi.org/10.1145/240455.240464

Han, J., Kamber, M., & Pei, J. (2012). *Data mining: Concepts and techniques* (3rd ed.). Morgan Kaufmann.

Aggarwal, M. (s. f.). *Diabetes risk prediction*. Kaggle. https://www.kaggle.com/datasets/mansiaggarwal88/diabetes-risk-prediction

Shearer, C. (2000). The CRISP-DM model: The new blueprint for data mining. *Journal of Data Warehousing*, 5(4), 13–22.

Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. En *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining* (pp. 29–39)